

Hợp nhất hai tầng cho định tuyến và phân lớp trong học liên tục hiệu quả tham số

Nguyễn Thiên Trường và Tống Quang Thái

Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội,
Hà Nội, Việt Nam
24022480@vnu.edu.vn, 24022450@vnu.edu.vn

Tóm tắt. Các hệ học liên tục hiệu quả tham số dùng bộ điều hợp riêng cho từng tác vụ phải lựa chọn bộ điều hợp khi không biết định danh tác vụ, trong khi định tuyến tốt hơn chưa chắc dẫn tới phân lớp tốt hơn. Chúng tôi đề xuất hợp nhất điểm số hai tầng bằng một đầu chiếu ngẫu nhiên (RP), được khớp bằng hồi quy ridge trên đặc trưng LoRA cố định của tác vụ đầu tiên. Các thống kê của đầu này được cộng dồn qua các tác vụ mà không lưu mẫu cũ hay thay đổi việc huấn luyện bộ điều hợp theo tác vụ. Cùng một điểm RP được dùng tại hai điểm quyết định: hợp nhất đề xuất tác vụ trước khi đối sánh lại và hợp nhất lớp có cổng biên sau đó. Trên ba bộ chuẩn và bốn seed, phương pháp tăng độ chính xác đề xuất DRM 1.10–2.26 điểm phần trăm và độ chính xác phân lớp 0.69–1.50 điểm. Một lưới một seed trên bốn bộ dữ liệu và năm thiết lập tiền huấn luyện cho thấy độ chính xác tăng ở cả hai mươi phép so sánh. Các đối chứng cùng đặc trưng và ablation có điều kiện tách đóng góp của bộ phân lớp RP khỏi tác động của định tuyến và cổng. Các tác động phụ thuộc bộ dữ liệu và cấu hình hợp nhất; không thành phần nào luôn có lợi. Kết quả ủng hộ cải thiện dự đoán, nhưng không cho thấy sự giảm nhất quán của quên hay suy giảm chuyển giao ngược.

Từ khóa: Học liên tục · Tinh chỉnh hiệu quả tham số · Định tuyến tham số · Chiếu ngẫu nhiên · Hợp nhất tín hiệu.

1 Giới thiệu

Học liên tục yêu cầu mô hình tiếp nhận một chuỗi tác vụ mà không đánh mất kiến thức đã học trước đó. Tinh chỉnh hiệu quả tham số thích nghi một mạng xương sống tiền huấn luyện đóng băng bằng một lượng nhỏ tham số. Một họ phương pháp quan trọng duy trì prompt hoặc bộ điều hợp riêng cho từng tác vụ và lựa chọn chúng khi suy luận [5, 3]. Các phương pháp này có thể không lưu mẫu cũ, nhưng bảo toàn tham số không đồng nghĩa với bảo toàn độ chính xác.

Trong họ này, định danh tác vụ không được biết khi suy luận và việc chọn tham số tự nó là một bài toán dự đoán. Bộ điều hợp sai có thể tạo ra đặc trưng không phù hợp. Kho lớn hơn, tổ hợp có trọng số attention và đối sánh lại tường minh là các hướng xử lý khác nhau [4, 7, 1]. Tuy nhiên, chọn bộ điều hợp phù hợp hơn và dự đoán đúng lớp là hai mục tiêu khác nhau: đầu phân lớp dùng

chung có thể khôi phục sau lỗi định tuyến, còn thay đổi định tuyến cũng có thể phá một dự đoán vốn đã đúng.

Chúng tôi bổ sung một bộ dự đoán hỗ trợ gồm đặc trưng từ bộ điều hợp tác vụ đầu, phép chiếu ngẫu nhiên đóng băng và bộ phân lớp ridge được khớp từ thống kê cộng dồn theo RanPAC [2]. Việc khớp chỉ dùng dữ liệu tác vụ hiện tại, không thay đổi huấn luyện LoRA/TII và không lưu mẫu. Điểm số của nó sửa đề xuất tác vụ trước đối sánh lại rồi được trộn với logit lớp cuối, với trọng số lớn hơn khi biên giữa hai lớp đứng đầu của bộ phân lớp chính nhỏ đi.

Đóng góp. Chúng tôi đóng góp (i) một bộ dự đoán RP dùng chung cho hợp nhất đề xuất tác vụ và hợp nhất lớp có cổng biên, (ii) các đối chứng cùng đặc trưng và ablation có điều kiện trên bốn seed, và (iii) khảo sát bốn bộ dữ liệu, năm thiết lập tiền huấn luyện cùng phân tích độ nhạy trọng số. Điểm mới nằm ở cách tích hợp tại hai điểm quyết định và đánh giá nó, không phải bản thân hồi quy ridge. Chúng tôi phân biệt mức tăng phân lớp với khả năng ghi nhớ, và khả năng bổ sung oracle với các sửa chữa thực sự đạt được.

2 Công trình liên quan

Kho tham số và yêu cầu lựa chọn. L2P [4] và DualPrompt [5] dùng truy vấn từ mạng xương sống đóng băng để chọn tham số nhẹ trong một kho. CODA-Prompt [7] kết hợp prompt bằng trọng số attention. HiDe-Prompt [3] tách dự đoán trong tác vụ, suy luận định danh tác vụ và dự đoán thích nghi theo tác vụ, đồng thời chỉ ra suy luận định danh là nút thắt. HRM-PET [1] dùng bộ điều hợp LoRA [6] và đối sánh lại để xem xét lại lựa chọn ban đầu. MoTE [14] kết hợp các chuyên gia theo tác vụ; DLEPEM [15] kết hợp prototype chung và prototype đã thích nghi để đối sánh.

Nghiệm dạng đóng trong học liên tục. Bộ phân lớp dạng đóng bảo toàn đóng góp cũ thông qua thống kê cộng dồn của đặc trưng cố định. APER [8] thích nghi mạng xương sống ở tác vụ đầu, sau đó dùng đặc trưng đóng băng và prototype lớp. ACIL [20] dùng bình phương tối thiểu đệ quy, thay bộ đệm mẫu bằng thống kê tương quan và khôi phục nghiệm chung tương ứng. DS-AL [21] thêm một luồng giải tích thứ hai. RanPAC [2] áp dụng phép chiếu ngẫu nhiên cố định lên đặc trưng đóng băng, cộng dồn thống kê bậc hai và giải hệ ridge.

Chúng tôi kế thừa phép chiếu, phép cộng dồn Gram và lời giải ridge của RanPAC, nhưng giữ quy trình định tuyến bộ điều hợp và tham khảo đầu này tại hai điểm quyết định thay vì dùng nó làm bộ dự đoán duy nhất.

Hiệu chỉnh bộ phân lớp sau huấn luyện. Học tăng dần theo lớp thường thiên lệch dự đoán về các lớp gần đây [9]. iCaRL [10] dùng trung bình exemplar gần nhất; BiC [11] học hiệu chỉnh logit affine trên dữ liệu giữ lại; Weight Aligning [12] khớp chuẩn trọng số của lớp mới và cũ; LUCIR [13] chuẩn hóa đặc trưng và trọng số. Phép hợp nhất của chúng tôi giữ cố định các bộ điều hợp,

đầu phụ và đầu dùng chung. Nó không giữ exemplar nhưng cần dữ liệu tác vụ hiện tại để khớp đầu RP.

Thách thức còn lại. Sự không nhất quán prompt/bộ phân lớp giữa huấn luyện và kiểm thử có thể làm giảm chất lượng dự đoán [18]; đối sánh lại xử lý lựa chọn tham số nhưng không cung cấp một bộ dự đoán lớp độc lập. Chúng tôi tiếp nhận giao diện đối sánh lại của HRM-PET [1], giữ nguyên việc huấn luyện bộ điều hợp và bộ phân lớp, rồi thử bằng chứng RP bổ sung trước và sau đối sánh lại. Điều này khác với thay thế việc chọn bộ điều hợp bằng một bộ phân lớp giải tích.

3 Phương pháp

3.1 Phát biểu bài toán

Học tăng dần theo lớp (CIL) nhằm học T tác vụ đồng thời giảm quên. Tác vụ t cung cấp các ảnh có nhãn $\mathcal{D}_t = \{(x_i^t, y_i^t)\}_{i=1}^{n_t}$ từ tập lớp $\mathcal{C}_t$, với $\mathcal{C}_t \cap \mathcal{C}_{t'} = \emptyset$ khi $t \neq t'$. Chỉ dữ liệu tác vụ hiện tại được dùng để huấn luyện; ảnh cũ không bao giờ được giữ lại. Khi suy luận, định danh tác vụ không biết trước và dự đoán trải trên mọi lớp đã thấy.

Thiết lập PET theo tác vụ của chúng tôi [3, 1] đóng băng tham số mạng xương sống θ_{ptm} và duy trì các bộ điều hợp LoRA $\mathcal{P} = \{p_1, \dots, p_T\}$, mỗi tác vụ một bộ, cùng đầu phân lớp dùng chung g_θ . Dự đoán chính cần chọn bộ điều hợp; nhánh RP cố định độc lập với tác vụ được suy ra.


Chúng tôi phân biệt bốn vector điểm lớp: điểm TII trần u , logit đầu dùng chung sau lượt thích nghi ban đầu r , logit sau đối sánh lại cuối cùng ℓ , và điểm RP s . Ánh xạ từ lớp sang tác vụ là $\mathcal{T}(\cdot)$. Đầu phụ g_ω ánh xạ đặc trưng trần thành u , cho $t_0 = \mathcal{T}(\arg \max_c u_c)$. Lượt thích nghi ban đầu cho $r = g(\phi(x; p_{t_0}))$. DRM chỉ đánh giá bộ điều hợp được đề xuất khi $t_{\text{DRM}} \neq t_0$. CRM dùng độ tin cậy entropy tổng quát của r , thử tác vụ chứa lớp xếp thứ hai, rồi giữ logit theo log-sum-exp; nó không bị giới hạn bởi sự đồng thuận giữa các đề xuất tác vụ và không chạy ở tác vụ 1. Mọi lượt thích nghi dùng chung g ; ℓ là logit lớp được giữ lại. Ký hiệu $z(\cdot)$ là chuẩn hóa theo từng mẫu, với độ lệch chuẩn tổng thể có ngưỡng dưới 10^{-6} .

3.2 Nguồn bằng chứng thứ hai


Chúng tôi khớp một đầu RP sau mỗi tác vụ và tái dùng điểm của nó trong hai phép hợp nhất khi suy luận. Các mô-đun PET hiện có không nhận thêm cập nhật gradient. Hình 1 phân biệt logit thích nghi ban đầu với điểm TII trần và thể hiện cả hai đường tái sử dụng.

Đầu RP theo RanPAC [2]. Đặc trưng $f \in \mathbb{R}^d$, $d = 768$, là vector cột từ ViT-B/16 gắn bộ điều hợp LoRA của tác vụ đầu tiên (p_1 ở đây, chỉ số 0 trong mã). Đặc trưng này không chuẩn hóa và được giữ cố định khi cộng dồn lần suy luận; đối bộ điều hợp giữa các tác vụ sẽ trộn các không gian không tương thích.


(a) Học các mô-đun PET trên tác vụ $\mathbb{E}$: cố định T: huấn luyện A: cập nhật giải tích



(b) Suy luận (tất cả cố định) Cùng ảnh x ; dùng chung trọng số ViT và đầu thích nghi g



(c) Khớp RP trên tác vụ hiện tại: chỉ cập nhật thống kê và trọng số đầu ra



Hình 1. Vòng đời tham số và hợp nhất hai tầng. (a) Quy trình PET kế thừa huấn luyện bộ điều hợp/các đầu, không huấn luyện mạng xương sống. (b) Mọi mô-đun đều cố định: Tầng 1 sửa đề xuất DRM; Tầng 2 đặt cổng cho hợp nhất lớp bằng ℓ . Một vector điểm RP phục vụ cả hai tầng. (c) Dữ liệu huấn luyện hiện tại cập nhật giải tích G, C, W_{out} với p_1, W cố định. Chỉ các lớp/tác vụ đã thấy tham gia. Ảnh và cột chỉ minh họa, không phải dự đoán đo được. Ảnh: T. G. Barnes/USFWS (phạm vi công cộng).

Phép chiếu và thống kê bậc hai. Ta mở rộng f lên $M = 10^4$ chiều và giữ hai ma trận cộng dồn:

$$h = \text{ReLU}(W^\top f) \in \mathbb{R}^M, \quad W \in \mathbb{R}^{d \times M}, \quad W_{jk} \sim \mathcal{N}(0, 1), \quad (1)$$

$$G = \sum_n h_n h_n^\top \in \mathbb{R}^{M \times M}, \quad C = \sum_n h_n \mathbf{e}_{y_n}^\top \in \mathbb{R}^{M \times |\mathcal{Y}|}, \quad (2)$$

trong đó $\mathbf{e}_y$ là vector cơ sở của lớp y . Mỗi mẫu huấn luyện của tác vụ hiện tại đóng góp đúng một lần; G và C được cộng dồn ở float64. W được sinh một lần với seed 1993 rồi đồng băng.

Phép mở rộng phi tuyến cho phép hàm quyết định giàu hơn một đầu tuyến tính trên f . Nếu không có ReLU, $W^\top f$ vẫn tuyến tính theo f và không tăng khả năng phân tách. Điều này không bảo đảm dữ liệu mở rộng trở nên phân tách tuyến tính.

Phân lớp bằng hồi quy ridge. Trọng số đầu ra là nghiệm dạng đóng của bài toán bình phương tối thiểu có điều chuẩn:

$$W_{\text{out}} = (G + \lambda I)^{-1} C \in \mathbb{R}^{M \times |\mathcal{Y}|}, \quad s = W_{\text{out}}^\top h \in \mathbb{R}^{|\mathcal{Y}|}. \quad (3)$$

Cài đặt giải hệ có điều chuẩn thay vì tính ma trận nghịch đảo.

Hai tính chất kế thừa. Với ánh xạ đặc trưng cố định, các tổng trong (2) bảo toàn đóng góp trước đó và cho nghiệm ridge chung trên mọi đặc trưng đã quan sát, độc lập với thứ tự mẫu trong số học chính xác. Dung lượng lưu trữ độc lập với số mẫu và không giữ đặc trưng theo từng mẫu. Điều này không đồng nghĩa bất biến bit theo số thực dấu phẩy động hay không quên: lớp mới vẫn có thể vượt điểm lớp cũ. Đổi tác vụ đầu cũng làm đổi bộ điều hợp và do đó đổi ánh xạ đặc trưng.

3.3 Hợp nhất hai tầng

Cả hai tầng trộn các nguồn có thang điểm khác nhau. Trộn trực tiếp có thể khiến trọng số danh nghĩa không phản ánh đúng ảnh hưởng. Mỗi nguồn được chuẩn hóa theo từng mẫu:

$$z(v) = \frac{v - \text{mean}(v)}{\sigma_\epsilon(v)}, \quad \sigma_\epsilon(v) = \max\{\text{std}(v), 10^{-6}\}, \quad (4)$$

trong đó std là độ lệch chuẩn tổng thể. Các moment được tính trên các tác vụ đã thấy ở Tầng 1 và các lớp đã thấy ở Tầng 2, loại bỏ mục chưa thấy.

Tầng thứ nhất: hợp nhất ở cấp định tuyến. Tầng 1 chạy sau lượt thích nghi ban đầu và trước DRM. Đầu vào là r , tức logit của đầu dùng chung dưới bộ điều hợp được TII trần chọn, không phải logit phụ u . Cả r và điểm RP s được ánh xạ về tác vụ đã thấy bằng $r_t^{\text{task}} = \max_{c \in \mathcal{C}_t} r_c$ and $s_t^{\text{task}} = \max_{c \in \mathcal{C}_t} s_c$ for $t = 1, \dots, \hat{T}$, trong đó $\hat{T}$ là số tác vụ đã thấy; lớp thuộc tác vụ chưa thấy không tham gia phép cực đại nào. Hai vector được trộn sau chuẩn hóa:

$$\text{fused} = w z(r^{\text{task}}) + (1 - w) z(s^{\text{task}}), \quad \hat{t}_{\text{DRM}} = \arg \max_t \text{fused}_t. \quad (5)$$

Khi mới thấy một tác vụ, độ lệch chuẩn bằng không nên ngưỡng dưới giữ phép tính hữu hạn. Tác vụ hợp nhất thay đề xuất DRM cơ sở $\mathcal{T}(\arg \max r)$; phép khớp TII ban đầu, quy tắc ứng viên CRM, phép kiểm tra độ tin cậy và đầu dùng chung không đổi. Khi $w = 1$, thứ tự giống r^{task} và khôi phục đề xuất đó; để khôi phục đầy đủ đường cơ sở còn cần $\beta = 0$.

Tầng thứ hai: hợp nhất có cổng ở cấp phân lớp. Vì ℓ đến từ đầu dùng chung, nó vẫn có thể dự đoán đúng lớp dù định tuyến sai. Do đó ta dùng chính đầu chiếu làm bộ phân lớp phụ, lần này lấy điểm lớp s . Phép trộn cố định sẽ

làm thay đổi cả dự đoán chính vốn tự tin; thay vào đó ta giảm tỷ trọng RP khi biên xác suất của hai lớp đứng đầu tăng, đồng thời thừa nhận rằng dự đoán tự tin vẫn có thể sai:

$$\beta_i = \beta \left(1 - \frac{p_{(1)} - p_{(2)}}{p_{(1)} + p_{(2)}} \right), \quad \beta = 0.5, \quad (6)$$

trong đó $p_{(1)} \geq p_{(2)}$ là hai xác suất lớn nhất của softmax(ℓ) trên các lớp đã thấy. Chia cho tổng khiến đại lượng chỉ phụ thuộc tỷ lệ $p_{(2)}/p_{(1)}$, nên công đo mức lớp đứng đầu bị đe dọa thay vì tổng khối lượng xác suất của cặp. Tỷ trọng RP tiến về không khi lớp đầu áp đảo và đạt β khi hai lớp bằng nhau: đây là trọng số liên tục, không phải phép kiểm tra nhị phân.

Phép trộn tái dùng (4) rồi ánh xạ kết quả trở lại thang của ℓ :

$$m_i = (1 - \beta_i) z(\ell_i) + \beta_i z(s_i), \quad (7)$$

$$\hat{\ell}_i = m_i \cdot \sigma_\epsilon(\ell_i) + \text{mean}(\ell_i) \in \mathbb{R}^{|\mathcal{Y}|}. \quad (8)$$

Ánh xạ affine dương giữ thứ hạng và khôi phục một thang tham chiếu cho cross-entropy, không bảo đảm hiệu chuẩn: với các vector chuẩn hóa không suy biến có tương quan ρ và ngưỡng dưới không kích hoạt, phương sai hỗn hợp là $(1 - \beta_i)^2 + \beta_i^2 + 2\beta_i(1 - \beta_i)\rho$, không nhất thiết bằng một. Khi $\beta = 0$, tầng này giữ nguyên ℓ .

Chi phí. Đầu này thêm một lượt truyền xuôi qua bộ điều hợp cho mỗi mẫu, dùng chung cho cả hai tầng hợp nhất. Đây không phải tổng overhead đo được: thay đổi đề xuất DRM cũng có thể làm đổi số lượt đánh giá bộ điều hợp.

Với mỗi tác vụ, đầu cộng dồn G và C trên tập huấn luyện hiện tại rồi giải một hệ ridge. Các mảng được lưu có độ phức tạp $O(M^2 + M|\mathcal{Y}| + dM)$: G có M^2 phần tử, C và W_{out} mỗi ma trận có $M|\mathcal{Y}|$ phần tử, còn phép chiếu có dM phần tử. Với số chiều và sức chứa lớp cố định, dung lượng không tăng theo số mẫu đã quan sát. Ma trận Gram chiếm ưu thế trong thiết lập của chúng tôi. Với $M = 10^4$, nó có 10^8 phần tử float64, tương đương 800 MB. Cùng bản sao có điều chuẩn và nhân tử Cholesky, ba ma trận cần xấp xỉ 2.4 GB; đây là ước lượng giải tích, không phải đỉnh bộ nhớ tổng đã đo. Một lượt đánh giá lịch sử gồm mười tác vụ trên ImageNet-R mất 283 s với một RTX 4090 và batch 24; chi phí từng pha và chi phí tăng thêm so với đường cơ sở chưa được đo.

4 Thực nghiệm

4.1 Thiết lập

Mạng xương sống là ViT-B/16 [22], tiền huấn luyện trên ImageNet-21K. LoRA hạng 8 sửa các phép chiếu key/value trong năm block đầu. Khảo sát bốn seed chia ImageNet-R [23], CIFAR-100 [24] và CUB-200-2011 [25] thành 10 tác vụ, mỗi tác vụ lần lượt có 20, 10 và 20 lớp. Trong lưới, CUB được thay bằng ImageNet-A [26]

(10×20 lớp) và protocol năm bộ dữ liệu của [1] (mỗi miền là một tác vụ). Các thiết lập tiền huấn luyện gồm Sup-21K, MoCo-v3 [27], iBOT-1K/iBOT-21K [28] và DINO [29].

Mỗi seed (42–45) có tham số LoRA/TII được huấn luyện riêng; trọng số mạng xương sống tiền huấn luyện vẫn đóng băng. Hai phương pháp dùng cùng checkpoint đã lưu và cùng đường đánh giá. RP khớp mỗi ảnh huấn luyện của tác vụ hiện tại một lần bằng biến đổi đánh giá: đổi kích thước về 256, cắt giữa 224, rồi chuyển thành tensor; CIFAR còn dùng chuẩn hóa kênh theo cấu hình. Nhãn kiểm thử không tham gia phép khớp. Ta dùng $M = 10^4$, ReLU, $\lambda = 10^4$, không chuẩn hóa đặc trưng RP bổ sung, không hiệu chuẩn nhiệt độ và không ramp hợp nhất. Trừ khi nêu khác, toàn bài báo cáo $w = 0.7$ và $\beta = 0.5$, không phải cấu hình tốt nhất riêng theo từng bộ dữ liệu. Khảo sát độ nhạy chung ở Mục 4.6 có thiết lập $w = 0.6$ tốt hơn quan sát được; chúng tôi không chọn hồi tố cấu hình chính từ lưới kiểm thử đó. Hợp nhất bắt đầu từ tác vụ 1; CRM giữ **En=gen**, ngưỡng -10 và ứng viên là lớp xếp thứ hai. Mã huấn luyện/đánh giá và tiền xử lý dữ liệu được quản lý phiên bản trong kho mã [30].

Acc@task trong bộ đánh giá phát hành đo đề xuất tác vụ DRM. Ở đường định tuyến theo lớp mặc định, CRM có thể đổi logit đầu ra mà không cập nhật định danh tác vụ chuyển vào metric này; vì thế đây không phải phép đo lựa chọn bộ điều hợp cuối sau CRM. Acc@1, Acc@5 và Loss dùng logit phân lớp cuối. Metric cuối lấy trung bình các giá trị theo tác vụ với trọng số bằng nhau, không gộp mọi ảnh kiểm thử. Gọi $a_{i,t}$ là độ chính xác phân lớp trên tác vụ i ở giai đoạn t , các metric ghi nhớ là

$$\text{Forgetting} = \frac{1}{T-1} \sum_{i=1}^{T-1} \left(\max_{i \leq t \leq T} a_{i,t} - a_{i,T} \right), \quad (9)$$

$$\text{Backward} = \frac{1}{T-1} \sum_{i=1}^{T-1} (a_{i,T} - a_{i,i}). \quad (10)$$

Cả hai trung bình loại tác vụ cuối, còn phép cực đại chỉ gồm các giai đoạn mà tác vụ i đã được học. Loss và Forgetting càng thấp càng tốt; độ chính xác và Backward càng cao càng tốt, kể cả khi Backward âm.

Khả năng tái lập và kiểm tra hợp lý. Sau khi sửa mặt nạ lớp chưa thấy, $w = 1, \beta = 0$ khôi phục đường không hợp nhất đến độ chính xác ghi log ở mọi giai đoạn, trên cả ba bộ dữ liệu và seed 42–45. Ví dụ, hai đường cùng cho ImageNet-R seed 42 Acc@1 bằng 74.0191. Đồng nhất này không có nghĩa các thiết lập hợp nhất trung gian luôn vô hại. Các lượt chính, đối chứng, lưới, ablation và chặn đoán đã được đánh giá lại; toàn bài dùng loss/retention đã sửa. Cả bốn mươi lượt trong lưới cùng các tensor mạng xương sống/bộ điều hợp đầu cố định đều đã được kiểm tra.

Bảng 1. Kết quả chính: Acc@1 cuối trung bình theo tác vụ (%). Các nhóm Sup-21K dùng mạng xương sống của bài; nhóm cuối dùng checkpoint AugReg của RanPAC. Giá trị bốn seed là trung bình $\pm$ độ lệch chuẩn mẫu; lượt đơn không có SD. Dấu gạch nghĩa là không đánh giá/báo cáo. IMR/IMA là ImageNet-R/A; CIFAR/CUB là CIFAR-100/CUB-200. Chữ đậm chỉ so sánh hai phương pháp được ghép trong từng nhóm giữa, không so mọi protocol.


Phương pháp	IMR	CIFAR	CUB	IMA	5-Datasets
<i>Bối cảnh Sup-21K đã công bố: trung bình ba seed từ [1]</i>					
DualPrompt [5]	68.79	86.60	–	39.76	76.09
S-Prompt++ [16]	69.68	88.81	–	39.10	83.38
CODA-Prompt [7]	70.03	86.94	–	30.96	62.54
LAE [17]	72.25	85.10	–	40.36	64.16
CPrompt [18]	69.24	83.18	–	37.60	71.72
InfLoRA [19]	72.24	85.28	–	42.12	71.97
HiDe-LoRA [3]	71.90	88.43	–	42.18	93.25
HRM-PET [1]	73.86	89.45	–	44.28	93.99
<i>Các lượt Sup-21K được ghép của chúng tôi: seed 42–45</i>					
HRM-PET	73.94 $\pm$ 0.48	89.78 $\pm$ 0.03	86.38 $\pm$ 0.25	–	–
Đầy đủ (chúng tôi)	75.18 $\pm$ 0.24	90.47 $\pm$ 0.05	87.88 $\pm$ 0.27	–	–
<i>Lượt Sup-21K của chúng tôi: seed 42 (trùng nhóm bốn seed)</i>					
HRM-PET	74.02	89.77	–	45.85	91.37
Đầy đủ (chúng tôi)	75.51	90.53	–	47.42	93.77
<i>AugReg-21K $\rightarrow$ 1K thăm dò: thứ tự 1993, seed huấn luyện 1</i>					
RanPAC [2]	77.44	–	–	–	–
HRM-PET	77.42	–	–	–	–
Đầy đủ (chúng tôi)	79.14	–	–	–	–

4.2 Kết quả chính

Bảng 1 kết hợp bối cảnh đã công bố và các phép so sánh có kiểm soát của chúng tôi. Các nhóm dùng tập seed khác nhau và nhóm cuối còn dùng trọng số tiền huấn luyện khác; không được gộp chúng thành một thứ hạng duy nhất. Số đã công bố được trích từ Bảng 1 của [1], không chạy lại ở đây. S-Prompt++ và HiDe-LoRA là các biến thể được đánh giá trong bộ chuẩn đó.

Với các so sánh bốn seed, chênh lệch được tính trong từng seed trước khi lấy trung bình. Hình 2 thể hiện khoảng Student- t ghép cặp 95%, $\bar{\Delta} \pm 3.182 s_{\Delta}/\sqrt{4}$, dùng SD mẫu. Với bốn seed, các khoảng này còn kém chính xác và giả định chênh lệch theo seed gần phân phối chuẩn; các metric tương quan không phải những xác nhận độc lập.

Dự đoán và ghi nhớ. Độ chính xác đề xuất DRM tăng 1.10–2.26 điểm và Acc@1 tăng 0.69–1.50 điểm, với khoảng ghép cặp dương trên cả ba bộ dữ liệu. Acc@5 cũng tăng 0.22–1.31 điểm với khoảng dương. Mức tăng Acc@1 lặp lại ở mọi seed, nhưng các mức tăng tổng hợp này không đếm bao nhiêu sửa đổi định



Hình 2. Chênh lệch ghép cặp trên seed 42–45; thanh sai số là khoảng t 95%, không phải SD của từng lượt. Giá trị dương tốt hơn cho dự đoán và Backward; giá trị âm tốt hơn cho Forgetting. Mọi khoảng của metric ghi nhớ đều cắt qua không. IMR, CIFAR và CUB lần lượt là ImageNet-R, CIFAR-100 và CUB-200.

tuyến thực sự sửa được dự đoán lớp. Cả sáu khoảng ghép cặp của metric ghi nhớ đều chứa không: chưa chứng minh được lợi ích nhất quán hay tính tương đương. Ví dụ, Forgetting trên CIFAR đối $-0.150 [-0.302, +0.002]$ và Backward đối $+0.136 [-0.015, +0.287]$. Không có biên tương đương được định trước.

Khả năng so sánh. Độ chính xác HRM-PET seed 42 của chúng tôi lệch trung bình ba seed đã công bố $+0.16$ trên ImageNet-R, $+0.32$ trên CIFAR-100, $+1.57$ trên ImageNet-A và -2.62 trên 5-Datasets. Vì vậy các hàng bối cảnh công bố không phải so sánh có kiểm soát với lượt chạy của chúng tôi; chênh lệch ghép cặp có lập phần hợp nhất được thêm vào.

Nhóm cuối dùng cùng trọng số AugReg: tiền huấn luyện ImageNet-21K rồi tinh chỉnh trên ImageNet-1K. Ảnh đã bấm và thứ tự lớp NumPy seed 1993 cũng giống nhau. RanPAC dùng cấu hình ID7 chính thức (SSF, 20 epoch chỉ ở tác vụ 1); TII/LoRA của chúng tôi dùng 20/50 epoch mỗi tác vụ. Torch seed là 1, nhưng augmentation, thời gian chạy và ngân sách huấn luyện khác nhau. Phương pháp đầy đủ tăng 1.69 điểm so với RanPAC và 1.72 so với HRM-PET được ghép. Kết quả một thứ tự này chưa chứng minh độ tin cậy đa thứ tự hay chi phí thấp hơn; các lượt lặp đang chờ không được đưa vào.

4.3 Khái quát qua các thiết lập tiền huấn luyện

Bảng 2 báo cáo lưới 4×5 bằng một đường mã ở seed 42. Cả hai mươi ô tăng Acc@1 từ $+0.59$ đến $+3.58$ điểm, trên đường cơ sở Acc@1 31.8–93.8; mức tăng Acc@task là $+0.97$ đến $+4.57$.

Độ chính xác cuối trên các tác vụ cũ tăng ở mọi ô (trung bình $+1.83$), so với $+1.58$ tại thời điểm học. Backward, tức hiệu giữa hai đại lượng, xấu đi ở năm

Bảng 2. Chênh lệch Acc@1 (điểm phần trăm), phương pháp đầy đủ trừ HRM-PET được ghép, seed 42. Mọi ô dùng cùng $w = 0.7$, $\beta = 0.5$ và cổng biên; đây là so sánh một seed, không phải khoảng tin cậy.

Tiền huấn luyện	ImageNet-R	CIFAR-100	ImageNet-A	5-Datasets
Sup-21K	+1.49	+0.76	+1.57	+2.40
MoCo-v3	+1.89	+2.12	+2.41	+1.41
iBOT-1K	+2.52	+2.06	+3.58	+0.85
iBOT-21K	+2.55	+1.80	+2.63	+0.59
DINO	+2.68	+2.03	+0.97	+0.75

ô vì độ chính xác lúc học tăng nhiều hơn, không phải độ chính xác cuối giảm. Phân rã này dùng log theo tác vụ đã làm tròn và chỉ mang tính mô tả.

4.4 Khảo sát loại bỏ thành phần

Bảng 3 cô lập bộ dự đoán RP cùng đặc trưng và các biến thể hợp nhất lớp. Mọi biến thể RP dùng cùng đặc trưng tác vụ đầu cố định và cấu hình ridge. RP-only dự đoán trực tiếp từ s và không tái lập toàn bộ protocol RanPAC. Class-only tắt hợp nhất định tuyến ($w = 1$); cả hai biến thể class-only dùng $\beta = 0.5$.

Bảng 3. So sánh thành phần: Acc@1 cuối (%), trung bình $\pm$ SD mẫu trên seed 42–45. Phương pháp đầy đủ dùng $w = 0.7$, $\beta = 0.5$ và cổng biên. Chữ đậm đánh dấu trung bình cao nhất mỗi cột, không phải tuyên bố ý nghĩa thống kê. Phương pháp đầy đủ không luôn tốt nhất trong các biến thể.

Biến thể	ImageNet-R	CIFAR-100	CUB-200
HRM-PET	73.94 $\pm$ 0.48	89.78 $\pm$ 0.03	86.38 $\pm$ 0.25
RP-only cùng đặc trưng	69.89 $\pm$ 0.17	88.80 $\pm$ 0.20	87.26 $\pm$ 0.27
Chỉ lớp, không cổng	74.49 $\pm$ 0.14	90.15 $\pm$ 0.16	88.01 $\pm$ 0.21
Chỉ lớp, có cổng	75.10 $\pm$ 0.21	90.50 $\pm$ 0.08	87.72 $\pm$ 0.26
Đầy đủ (chúng tôi)	75.18 $\pm$ 0.24	90.47 $\pm$ 0.05	87.88 $\pm$ 0.27

Phương pháp đầy đủ vượt RP-only trên cả ba bộ dữ liệu, nhưng hợp nhất lớp tạo ra phần lớn mức tăng so với HRM-PET. Chỉ lớp không cổng có trung bình CUB cao nhất, còn chỉ lớp có cổng cao nhất trên CIFAR; chúng tôi giữ một cấu hình chung thay vì chọn người thắng khác nhau cho từng bộ dữ liệu.

Định tuyến cùng hợp nhất lớp không cổng. Ablation năm mạng xương sống trên ImageNet-R dùng seed 42; Acc@1 cơ sở từ 68.47 đến 74.02. Chúng tôi báo cáo chênh lệch giữa các biến thể đã chỉ định. Biến thể chỉ định tuyến và chỉ lớp không cổng tăng Acc@1 trên từng mạng lần lượt +0.29–+0.73 và

+0.51–+3.07. Thêm định tuyến vào hợp nhất lớp không cổng làm Acc@1 đổi –0.07 đến +0.02, chưa chứng minh tương đương.

Acc@1 của đầy đủ trừ chỉ lớp có cổng là +0.13, +0.29, +0.78, +0.43 và +0.77 trên Sup-21K, MoCo-v3, iBOT-1K, iBOT-21K và DINO ở seed 42. Các mức tăng một seed này chưa chứng minh độ tin cậy hay lợi ích ghi nhớ: Forgetting của MoCo-v3 tăng từ 3.44 lên 3.69. Cổng cũng không luôn có lợi: đầy đủ trừ đầy đủ không cổng là –0.26 Acc@1 trên MoCo-v3 và –0.54 trên iBOT-1K.

Đóng góp có điều kiện trên bốn seed. Đầy đủ trừ chỉ lớp có cổng đo tác động định tuyến có điều kiện; có cổng trừ không cổng trong biến thể chỉ lớp đo tác động cổng khi không hợp nhất định tuyến. Đây không phải các hiệu ứng tăng độc lập.

Hiệu ứng định tuyến có điều kiện là +0.083 [+0.026, +0.140] trên ImageNet-R, –0.030 [–0.085, +0.025] trên CIFAR-100 và +0.156 [+0.055, +0.257] trên CUB-200. Hiệu ứng cổng là +0.603 và +0.355 trên hai bộ đầu, đều loại không, và –0.284 [–0.570, +0.002] trên CUB-200. Mỗi cặp cộng lại bằng thay đổi của đầy đủ so với chỉ lớp không cổng: +0.69, +0.33 và –0.13, sai số dưới 0.005. Định tuyến dương trên hai bộ và chưa rõ trên CIFAR. Ước lượng cổng trên CUB âm nhưng khoảng chứa không nên chưa chứng minh có hại. Phương pháp đầy đủ vẫn cải thiện so với HRM-PET trong Bảng 1. Chỉ tăng hợp nhất thứ nhất làm thay đổi Acc@task.


4.5 Chẩn đoán tính bổ sung

Theo Mục 4.1, các chẩn đoán seed 42 cân bằng tác vụ. Trên ImageNet-R, độ chính xác định tuyến TII trần là 63.80%, đề xuất DRM cơ sở là 77.79% và bộ định tuyến RP là 77.12%. Hợp oracle TII–RP đạt 82.99%. Lấy tỷ lệ RP đúng/TII sai chia cho tỷ lệ lỗi TII cho 53.0%, so với 62.0% trên CIFAR-100 và 46.9% trên CUB-200. Đây là tỷ lệ khôi phục cân bằng theo tác vụ, không phải số ảnh gộp hay độ chính xác hợp nhất đạt được. Chúng so TII trần với RP, không so logit thích nghi của Tầng 1 với RP.

Tính bổ sung cũng tồn tại ở cấp lớp. Trong chẩn đoán chỉ định tuyến ($w = 0.7$, $\beta = 0$), độ chính xác ImageNet-R là 74.31% cho đầu đã định tuyến và 70.08% cho RP, với hợp oracle 78.89%. RP đúng khi đầu đã định tuyến sai trên 4.58 điểm phần trăm cân bằng theo tác vụ, so với 2.43 trên CIFAR-100 và 3.87 trên CUB-200. Tiềm năng này tạo động lực tái dùng s để phân lớp, nhưng không đếm sửa chữa hay tác hại thực tế của hợp nhất đầy đủ.

4.6 Độ nhạy với trọng số hợp nhất

Hai trọng số được cố định tuần tự: w trước khi tầng hai tồn tại và β sau đó, nên tầng hai có thể đã dịch chuyển tối ưu của tầng đầu. Hình 3 vẽ lưới chung trên ImageNet-R ở seed 42 khi cổng biên hoạt động. Đây là phân tích độ nhạy thăm dò trên tập kiểm thử, không phải tập xác thực độc lập để chọn siêu tham số.



Hình 3. Độ nhạy trọng số, ImageNet-R seed 42. Trục dọc được phóng để thấy chênh lệch nhỏ; các điểm là lượt chạy riêng, không phải trung bình hay khoảng tin cậy. Đường đứt đánh dấu $w = 0.7$ được báo cáo. Điểm lưới tốt nhất quan sát được là $(w, \beta) = (0.6, 0.5)$ với 75.61%.

Lưới ưu tiên $\beta = 0.5$ tại mọi w ; cực đại nằm ở $w = 0.6$, không phải 0.7 được báo cáo. Với $\beta = 0.5$, Acc@1 chỉ trải 0.11 điểm, so với khoảng một điểm của Acc@task. Trên bốn seed, 0.6 tăng Acc@task $+0.332$ $[+0.143, +0.522]$ và Acc@1 $+0.108$ $[-0.064, +0.280]$ so với 0.7 khi dùng cổng và $\beta = 0.5$; dấu của chênh lệch Acc@1 đảo ở seed 43. Vì vậy, 0.6 là cực đại lưới quan sát được, nhưng lợi thế phân lớp so với 0.7 nhỏ và chưa chắc chắn trên bốn seed. Chúng tôi giữ 0.7 làm cấu hình báo cáo chung, không gọi nó là tối ưu, và công bố toàn bộ kết quả độ nhạy thay vì chọn cấu hình chính sau khi xem kết quả kiểm thử. Điều này không loại bỏ thiên lệch do quá trình phát triển.

4.7 Hạn chế

ImageNet-R và CUB đã tham gia quá trình phát triển; không bộ nào là holdout chưa được tối. Thêm seed không loại bỏ thiên lệch lựa chọn. Mức trùng giữa CUB và dữ liệu tiền huấn luyện [25] chưa được kiểm tra. Lưới và ablation năm mạng xương sống chỉ dùng một seed; chỉ các chênh lệch ba bộ dữ liệu dùng bốn seed. Tác động định tuyến có điều kiện trên CIFAR chưa rõ, và lợi ích của cổng thay đổi theo mạng xương sống. Phép so sánh RanPAC bổ sung chỉ ghép trọng số tiền huấn luyện, ảnh và thứ tự lớp cho một lượt; ngân sách huấn luyện và thời gian chạy khác nhau, còn xác minh đa thứ tự chưa hoàn tất. Đối chứng RP-only trong Bảng 3 không phải tái lập RanPAC đầy đủ. Các đường cơ sở trích dẫn dùng cài đặt khác; kết quả Sup-21K trên 5-Datasets của chúng tôi thấp hơn số đã công bố. Lợi ích/tính tương đương về ghi nhớ chưa được chứng minh; chi phí theo pha và số sửa chữa/tác hại thực của hợp nhất đầy đủ chưa được đo. Bộ nạp bỏ qua hai tệp huấn luyện NotMNIST kích thước không, vốn cũng rộng trong kho nguồn cục bộ; chúng tôi không thay thế chúng.

5 Kết luận

Tái dùng một bộ dự đoán RP có đặc trưng cố định cho cả đề xuất tác vụ lẫn điểm lớp tăng độ chính xác phân lớp 0.69–1.50 điểm Acc@1 so với hệ PET được ghép trên ba bộ dữ liệu và bốn seed, mà không thay đổi huấn luyện bộ điều hợp hay lưu ảnh cũ. So sánh thành phần cho thấy hợp nhất lớp tạo phần lớn mức tăng; giá trị bổ sung của định tuyến và cổng mạng tính điều kiện, không phổ quát. Phương pháp cải thiện dự đoán nhưng chưa chứng minh giảm quên. Đo chi phí có kiểm soát và xác thực độc lập là ưu tiên cho các đánh giá tiếp theo.

Lời cảm ơn. Chúng tôi cảm ơn giảng viên hướng dẫn vì các góp ý cho bản thảo này.

Tài liệu tham khảo

1. Wang, W., Jia, G., Liu, X., Lin, L., Yang, J.: Hybrid re-matching for continual learning with parameter-efficient tuning. In: NeurIPS (2025)
2. McDonnell, M.D., Gong, D., Parvaneh, A., Abbasnejad, E., van den Hengel, A.: RanPAC: random projections and pre-trained models for continual learning. In: NeurIPS (2023)
3. Wang, L., Xie, J., Zhang, X., Huang, M., Su, H., Zhu, J.: Hierarchical decomposition of prompt-based continual learning: rethinking obscured sub-optimality. In: NeurIPS (2023)
4. Wang, Z., Zhang, Z., Lee, C.Y., Zhang, H., Sun, R., Ren, X., Su, G., Perot, V., Dy, J., Pfister, T.: Learning to prompt for continual learning. In: CVPR, pp. 139–149 (2022)
5. Wang, Z., Zhang, Z., Ebrahimi, S., Sun, R., Zhang, H., Lee, C.Y., Ren, X., Su, G., Perot, V., Dy, J., Pfister, T.: DualPrompt: complementary prompting for rehearsal-free continual learning. In: ECCV (2022)
6. Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W.: LoRA: low-rank adaptation of large language models. In: ICLR (2022)
7. Smith, J.S., Karlinsky, L., Gutta, V., Cascante-Bonilla, P., Kim, D., Arbel, A., Panda, R., Feris, R., Kira, Z.: CODA-Prompt: continual decomposed attention-based prompting for rehearsal-free continual learning. In: CVPR, pp. 11909–11919 (2023)
8. Zhou, D.W., Cai, Z.W., Ye, H.J., Zhan, D.C., Liu, Z.: Revisiting class-incremental learning with pre-trained models: generalizability and adaptivity are all you need. *Int. J. Comput. Vis.* **133**, 1012–1032 (2025). <https://doi.org/10.1007/s11263-024-02218-0>
9. Masana, M., Liu, X., Twardowski, B., Menta, M., Bagdanov, A.D., van de Weijer, J.: Class-incremental learning: survey and performance evaluation on image classification. *IEEE Trans. Pattern Anal. Mach. Intell.* **45**(5), 5513–5533 (2023)
10. Rebuffi, S.A., Kolesnikov, A., Sperl, G., Lampert, C.H.: iCaRL: incremental classifier and representation learning. In: CVPR, pp. 2001–2010 (2017)
11. Wu, Y., Chen, Y., Wang, L., Ye, Y., Liu, Z., Guo, Y., Fu, Y.: Large scale incremental learning. In: CVPR, pp. 374–382 (2019)
12. Zhao, B., Xiao, X., Gan, G., Zhang, B., Xia, S.T.: Maintaining discrimination and fairness in class incremental learning. In: CVPR, pp. 13208–13217 (2020)
13. Hou, S., Pan, X., Loy, C.C., Wang, Z., Lin, D.: Learning a unified classifier incrementally via rebalancing. In: CVPR, pp. 831–839 (2019)
14. Li, L., Wu, Z., Ji, Y.: MoTE: mixture of task-specific experts for pre-trained model-based class-incremental learning. *Knowledge-Based Systems* **324**, 113795 (2025). <https://doi.org/10.1016/j.knosys.2025.113795>
15. Zhao, H., Liu, R., Liu, Y.: Dynamic LoRA-experts and prototype-ensemble matching for class-incremental learning. *Applied Sciences* **16**(12), 6153 (2026). <https://doi.org/10.3390/app16126153>
16. Wang, Y., Huang, Z., Hong, X.: S-Prompts learning with pre-trained transformers: an Occam’s razor for domain incremental learning. In: NeurIPS (2022)
17. Gao, Q., Zhao, C., Sun, Y., Xi, T., Zhang, G., Ghanem, B., Zhang, J.: A unified continual learning framework with general parameter-efficient tuning. In: ICCV, pp. 11483–11493 (2023)
18. Gao, Z., Cen, J., Chang, X.: Consistent prompting for rehearsal-free continual learning. In: CVPR, pp. 28463–28473 (2024)

19. Liang, Y.S., Li, W.J.: InfLoRA: interference-free low-rank adaptation for continual learning. In: CVPR, pp. 23638–23647 (2024)
20. Zhuang, H., Weng, Z., Wei, H., Xie, R., Toh, K.A., Lin, Z.: ACIL: analytic class-incremental learning with absolute memorization and privacy protection. In: NeurIPS (2022)
21. Zhuang, H., He, R., Tong, K., Zeng, Z., Chen, C., Lin, Z.: DS-AL: a dual-stream analytic learning for exemplar-free class-incremental learning. In: AAAI, vol. 38(15), pp. 17237–17244 (2024). <https://doi.org/10.1609/aaai.v38i15.29670>
22. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., et al.: An image is worth 16x16 words: transformers for image recognition at scale. In: ICLR (2021). <https://arxiv.org/abs/2010.11929>
23. Hendrycks, D., Basart, S., Mu, N., Kadavath, S., et al.: The many faces of robustness: a critical analysis of out-of-distribution generalization. In: ICCV, pp. 8340–8349 (2021). <https://github.com/hendrycks/imagenet-r>
24. Krizhevsky, A.: Learning multiple layers of features from tiny images. Technical report, University of Toronto (2009). <https://www.cs.toronto.edu/~kriz/cifar.html>
25. Wah, C., Branson, S., Welinder, P., Perona, P., Belongie, S.: The Caltech-UCSD Birds-200-2011 dataset. Technical report CNS-TR-2011-001, California Institute of Technology (2011). https://www.vision.caltech.edu/datasets/cub_200_2011/
26. Hendrycks, D., Zhao, K., Basart, S., Steinhardt, J., Song, D.: Natural adversarial examples. In: CVPR, pp. 15262–15271 (2021)
27. Chen, X., Xie, S., He, K.: An empirical study of training self-supervised vision transformers. In: ICCV, pp. 9640–9649 (2021)
28. Zhou, J., Wei, C., Wang, H., Shen, W., Xie, C., Yuille, A., Kong, T.: iBOT: image BERT pre-training with online tokenizer. In: ICLR (2022). <https://arxiv.org/abs/2111.07832>
29. Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., Joulin, A.: Emerging properties in self-supervised vision transformers. In: ICCV, pp. 9650–9660 (2021)
30. Trường, N.T., Thái, T.Q.: Two-stage fusion for PET-based continual learning: implementation, paper-system revision 4989ab8 (2026). <https://github.com/Truong140206/Two-Stage-Fusion-for-PET-Based-Continual-Learning->